

DOKUMEN PENJELASAN PROPOSAL RISET

Decoding the Fire Escalome

Knowledge Discovery of Hidden Escalation Mechanisms in Indonesian Wildland Fires

Diajukan untuk: GEMASTIK XIX/2026 — Divisi Penambangan Data

Dokumen ini disusun untuk memberi gambaran utuh — konsep, metodologi, arsitektur data, dan landasan teknis — kepada dosen pembimbing.

Cara Membaca Dokumen Ini

Dokumen ini menjelaskan SATU ide riset secara utuh dalam empat lapis: (1) konsep & urgensi masalah, (2) arsitektur data — termasuk penjelasan teknis bagaimana data mentah dari Google Earth Engine diubah menjadi tabel siap-model, (3) klarifikasi metodologis mengenai ground truth (Bagian 4.3 — bagian yang paling sering dipertanyakan), dan (4) metodologi & model machine learning yang dipakai beserta nilai kebaruannya.

1. Ringkasan Eksekutif (5W + 1H)

Riset ini berangkat dari satu keresahan operasional: sistem deteksi kebakaran hutan dan lahan (karhutla) di Indonesia saat ini mendeteksi kejadian (occurrence), tapi tidak membedakan mekanisme eskalasinya. Akibatnya, BPBD dan Manggala Agni menangani ribuan titik panas per hari dengan strategi yang seragam, padahal kebakaran gambut yang membara pelan (smoldering) butuh penanganan yang sangat berbeda dari kebakaran permukaan yang menyebar cepat akibat angin.

Aspek	Penjelasan
WHAT	Knowledge Discovery in Databases (KDD) untuk menemukan taksonomi mekanisme eskalasi karhutla ("Escalation Archetypes") — bukan sekadar model prediksi biner. Output akhir: taksonomi archetype (peat/wind/drought/human-driven), Early-Warning Pattern Rules, dan Pattern Library terstruktur.
WHY	Operasional: penanganan one-size-fits-all tidak efektif karena strategi padam peat-driven berbeda total dari wind-driven. Keilmuan: sistem existing (SiPongi) bersifat occurrence-based, belum ada yang membongkar heterogenitas mekanisme eskalasi secara terstruktur di konteks Indonesia.
WHO	Pengguna akhir: BPBD & Manggala Agni (rekomendasi intervensi spesifik per archetype). Penerima manfaat ilmiah: komunitas Penambangan Data & Earth Observation.
WHERE	5 provinsi prioritas: Riau, Sumatera Selatan, Jambi (Sumatra) serta Kalimantan Barat dan Kalimantan Tengah (Kalimantan) — wilayah dengan konsentrasi lahan gambut dan titik panas tertinggi.
WHEN	Data historis 6 tahun (Januari 2020 – Agustus 2026) untuk training & taxonomy discovery. Fase operasional disimulasikan near real-time menggunakan FIRMS NRT (delay ~3 jam) + Open-Meteo Forecast API.

Aspek	Penjelasan
HOW	Integrasi multi-sumber data → sanitasi anti-false-positive → validasi ground truth (Bagian 4) → feature engineering spasial-temporal-interaksi → cost-sensitive modeling → archetype clustering → association rule mining → Pattern Library (detail lengkap di Bagian 5–7).

Istilah Kunci

- Escalome — istilah baru (analogi dari "genome") untuk merujuk pada keseluruhan mekanisme eskalasi kebakaran sebagai satu sistem yang bisa "dibongkar" (decoded), bukan sekadar diprediksi sebagai satu angka skor.
- Archetype — bukan sekadar "kategori", melainkan penegasan bahwa tiap tipe eskalasi punya trigger path (jalur pemicu) yang secara kualitatif berbeda, bukan cuma beda nilai fitur numerik.
- Triase Prediktif — output akhir sistem: prioritas patroli berbasis kombinasi archetype + tingkat risiko, bukan sekadar skor probabilitas tunggal yang generik.

2. Latar Belakang & Rumusan Masalah

Sistem pemantauan karhutla existing seperti SiPongi bekerja secara occurrence-based: mendeteksi bahwa titik api ada, tapi tidak menjelaskan mengapa satu titik api padam sendiri sementara titik lain di kondisi lingkungan yang tampak serupa justru bereskalasi menjadi kebakaran besar. Kesenjangan inilah yang menjadi titik tolak riset ini.

2.1 Research Questions

Kode	Pertanyaan Riset
RQ1 — Early Signals	Kombinasi sinyal spasial-temporal apa yang konsisten muncul sebelum eskalasi terjadi?
RQ2 — Anomalous Comparison	Mengapa cluster dengan kondisi lingkungan yang tampak serupa bisa punya nasib eskalasi yang berbeda?
RQ3 — Critical Transition	Interaksi faktor apa yang menjadi titik kritis (tipping point) sebelum eskalasi terjadi?
RQ4 — Escalation Archetypes	Apakah ada taksonomi pola eskalasi yang berbeda (peat-driven, wind-driven, drought-driven, human-induced)?

2.2 Hipotesis Utama (H1 — Paradoks Pareto)

H1 — diuji paling pertama, jadi prasyarat seluruh analisis lain

Cluster yang bereskalasi signifikan berjumlah kurang dari 10% dari total cluster aktif, tetapi menyumbang lebih dari 50% dari total akumulasi Fire Radiative Power (FRP) di wilayah prioritas.

Jika H1 terbukti, ini memberi justifikasi kuantitatif yang tegas untuk pendekatan triase presisi: sumber daya pemadaman yang terbatas semestinya diarahkan bukan ke jumlah titik terbanyak, melainkan ke segelintir cluster yang berkontribusi paling besar terhadap kerugian.

3. Arsitektur Data & Landasan Teknis

Bagian ini secara khusus menjelaskan dari mana data berasal dan bagaimana data itu diproses sebelum masuk ke tahap pemodelan — termasuk satu keputusan teknis penting yang mendasari seluruh pipeline: konversi data raster menjadi data tabular.

3.1 Mengapa Perlu Konversi Raster → CSV?

Sebagian besar data lingkungan yang relevan untuk riset ini (area terbakar, topografi, tutupan lahan, kekeringan vegetasi, kepadatan penduduk) tersedia di Google Earth Engine (GEE) dalam wujud raster — yaitu peta gambar yang tersusun dari piksel, di mana setiap piksel menyimpan satu nilai (misalnya ketinggian, atau kelas tutupan lahan). Sementara itu, data inti riset ini — titik panas dari NASA FIRMS — sudah berwujud tabel titik koordinat (CSV).

Agar kedua wujud data ini bisa digabungkan menjadi satu matriks fitur yang bisa "dimakan" oleh algoritma machine learning, seluruh data raster dari GEE diubah paksa menjadi titik koordinat — setiap piksel disampling menjadi satu baris berisi latitude, longitude, dan nilai atributnya. Proses ini dikerjakan oleh rangkaian skrip 02 sampai 07 dalam pipeline.

Kunci teknis yang membuat semua data ini bisa disatukan

Seluruh proses konversi raster → titik di atas di-setting pada skala resolusi yang sama, yaitu 500 meter. Dengan resolusi seragam ini, seluruh titik dari lima sumber data yang berbeda akan sejajar (grid-aligned) secara sempurna saat digabungkan melalui spatial join — tanpa proses ini, penggabungan antar sumber data akan menghasilkan mismatch koordinat dan noise interpolasi yang merusak kualitas fitur.

3.2 Tabel Sumber Data GEE yang Dikonversi (Raster → CSV)

Sumber Data	Wujud Asli (Raster)	Hasil Konversi (CSV)	Kegunaan dalam Riset
Burned Area (MODIS MCD64A1)	Peta gambar, tiap piksel menyimpan angka hari kalender (1–366) kapan area terbakar.	latitude, longitude, BurnDate	Ground truth independen untuk memvalidasi label eskalasi — menggantikan heuristik FIRMS semata (lihat Bagian 4). Elemen paling kritis dalam seluruh pipeline.
Topografi (SRTM DEM)	Peta ketinggian daratan (grayscale).	latitude, longitude, elevation, slope	Menentukan arah rambat api secara fisik; slope curam mempercepat penjaran api ke atas lereng — fitur pendukung archetype wind-driven.

Sumber Data	Wujud Asli (Raster)	Hasil Konversi (CSV)	Kegunaan dalam Riset
Land Cover (Google Dynamic World)	Peta klasifikasi warna (hijau=hutan, merah=kota, biru=air, dsb).	latitude, longitude, LandCover_Class (0–8)	Menyaring false positive dari area urban/industri, serta menentukan jenis bahan bakar (fuel type) di lokasi titik panas.
NDVI / Indeks Kekeringan (MODIS MOD13Q1)	Peta kepadatan klorofil/vegetasi.	latitude, longitude, NDVI_min	Indikator kekeringan bahan bakar vegetasi (rentang -0.2 s.d. 1.0) — fitur kunci untuk archetype drought-driven.
Kepadatan Penduduk (WorldPop)	Peta sebaran manusia resolusi 100 meter.	latitude, longitude, population	Estimasi jumlah jiwa per 500m ² — fitur pendukung archetype human-induced (kaitan dengan aktivitas manusia).

3.3 Data yang Tidak Melalui Konversi Raster → CSV

Dua kelompok data berikut sengaja tidak mengikuti alur konversi di atas, karena karakteristik data dan cara pemakaiannya berbeda:

Kelompok Data	Alasan Perlakuan Berbeda
FIRMS & Data Cuaca (Tier 0)	Sudah tersedia dalam wujud tabel CSV sejak sumbernya — tidak memerlukan konversi apa pun. Status: selesai dikerjakan (394.000+ baris FIRMS, 12.000+ baris Open-Meteo, periode 2020–2026).
Peta Gambut (KLHK / Wetlands International) & Jalan (OpenStreetMap)	Tetap dipertahankan dalam wujud Shapefile (.shp) karena strukturnya berupa poligon (gambut) dan garis (jalan). Data ini tidak disampling jadi titik, melainkan dipakai untuk menghitung jarak menggunakan pustaka GeoPandas — misalnya "berapa meter titik panas ini dari batas lahan gambut terdekat".

3.4 Tiering Prioritas Data (Bukan Semua Sumber Setara)

Dengan 8 sumber data dan tenggat kerja yang ketat, prioritas dibagi berdasarkan tier — sehingga bila waktu terbatas, kualitas riset tetap terjaga:

Tier	Sumber	Kegunaan	Akses
0 — Selesai	FIRMS, Open-Meteo	Deteksi titik panas + data cuaca	REST API (sudah selesai)
1 — Prioritas Tertinggi	MODIS Burned Area (MCD64A1)	Ground truth label eskalasi — seluruh jadwal berikutnya bergantung pada ini	Google Earth Engine: MODIS/061/MCD64A1
1	Peta Gambut (KLHK)	Indikator archetype peat-driven	Shapefile: data.go.id
1	SRTM DEM	Elevasi & kemiringan lereng	GEE: USGS/SRTMGL1_003

Tier	Sumber	Kegunaan	Akses
2 — Value Tinggi	Land Cover (Dynamic World)	Filter false positive & fuel type	GEE: GOOGLE/DYNAMICWORLD/V1
2	NDVI	Kekeringan bahan bakar vegetasi	GEE: MODIS NDVI 16-day
3 — Jika Waktu Cukup	OpenStreetMap (jarak jalan)	Indikator human-induced	Pustaka osmnx
3	WorldPop	Kepadatan penduduk	worldpop.org
4 — Opsional	GHSL (permukiman)	Redundan dengan WorldPop + OSM	GEE: JRC/GHSL

Catatan teknis: MCD64A1, Dynamic World, dan NDVI MODIS diakses lewat Google Earth Engine Python API (earthengine-api), berbeda dari REST API sederhana yang dipakai untuk FIRMS/Open-Meteo — ini kompetensi teknis baru yang perlu disiapkan sejak awal pengerjaan.

4. Pipeline Sanitasi Data (Anti False-Positive)

Sebelum data dipakai untuk pemodelan, titik panas mentah dari FIRMS melewati alur penyaringan bertingkat agar bebas dari false positive seperti flare gas industri atau area urban. Bagian 4.1 menjelaskan logika penggabungan datanya secara rinci, termasuk urutan yang sengaja disusun agar validitas kejadian diperiksa lebih dulu, sebelum penyaringan cakupan sektor.

4.1 Alur Kerja & Logika Penggabungan Data

Dua pertanyaan berbeda perlu dijawab secara berurutan dan terpisah: pertama, apakah titik panas ini benar-benar merupakan kejadian kebakaran nyata (validitas)? Kedua, apakah kejadian itu berada dalam cakupan sektor kehutanan yang menjadi fokus riset (scope)? Urutan pemrosesan sengaja disusun agar pertanyaan validitas dijawab lebih dulu, secara independen dari asumsi tutupan lahan.

```

[ Data Hotspot (FIRMS) ] —> [ Filter Land Cover ] —> [ Dataset Final ] [ Burned Area (MCD64A1) ] —> [ Spatial-Temporal Join ]
      (validasi kejadian)           (kualifikasi sektor)

```

Langkah 1 — Spatial-Temporal Join: Hotspot × Burned Area (validasi kejadian)

- Tujuan: memvalidasi kejadian kebakaran secara spasial DAN temporal (waktu), bukan cuma lokasi.

Kenapa perlu digabung? Hotspot (FIRMS) adalah data titik api aktif pada saat satelit melintas (deteksi anomali suhu) — sesaat, bukan konfirmasi kejadian penuh. Burned Area (MCD64A1) adalah polygon/luasan area yang benar-benar tercatat terbakar. Titik hotspot yang jatuh di dalam atau berdekatan dengan polygon burned area, pada rentang tanggal yang sama, menjadi indikator kuat (ground truth)

bahwa di titik tersebut benar terjadi karhutla nyata — bukan sekadar anomali suhu sesaat yang bisa jadi flare gas, panas industri, atau gangguan sensor.

Langkah 2 — Filtering Land Cover (kualifikasi sektor)

- Tujuan: menyaring hasil Langkah 1 agar sesuai fokus riset, yaitu sektor kehutanan/vegetasi.

Kenapa langkah ini penting, dan kenapa dijalankan SETELAH validasi, bukan sebelum? Tidak semua kejadian yang lolos validasi Langkah 1 adalah kebakaran hutan — bisa saja hotspot dan burned area sama-sama tercatat di area permukiman, industri, flare gas pertambangan, atau lahan pertanian non-hutan. Menjalankan filter ini setelah validitas kejadian dipastikan (bukan sebelumnya) memastikan tidak ada kejadian kebakaran hutan nyata yang gugur lebih dulu hanya karena ketidaktepatan peta tutupan lahan di piksel tertentu.

Cara kerja:

- Ambil data Land Cover (Google Dynamic World / ESA WorldCover) dan Peta Gambut (KLHK).
- Lakukan spatial join/overlay koordinat hasil Langkah 1 dengan data Land Cover tersebut.
- Filter hanya kelas tutupan lahan kategori hutan/vegetasi: Hutan Hujan Tropis (Primary/Secondary Forest), Hutan Gambut (Peatland Forest), dan Semak Belukar/Shrubland. Kelas urban, industri, dan pertanian non-hutan dibuang.

Ringkasan untuk Proposal / Laporan

1. Identifikasi Kejadian — menggabungkan deteksi titik api aktif (Hotspot/FIRMS) dengan area bekas terbakar (Burned Area) untuk memvalidasi realitas kejadian secara independen.

2. Kualifikasi Sektor — memfilter koordinat yang sudah tervalidasi berdasarkan klasifikasi Land Cover, memastikan sampel data yang dianalisis khusus berada pada kawasan hutan dan lahan vegetasi target.

4.1b Tahapan Pipeline Lengkap (urutan final, terkoreksi)

Tahap	Proses
1. Deteksi Awal	NASA FIRMS (VIIRS 375m) — deteksi anomali suhu permukaan.
2. Validasi Spasial-Temporal	Spatial-temporal join dengan MCD64A1 Burned Area (lihat Langkah 1 di atas) — memvalidasi kejadian, independen dari asumsi tutupan lahan.
3. Filtering Land Cover	Overlay dengan Land Cover & Peta Gambut (lihat Langkah 2 di atas). Dipertahankan: hutan, gambut, semak belukar. Dibuang: urban, industri, flare oil & gas.
4. Dataset Final Kebakaran Hutan	Dataset kandidat kebakaran hutan yang sudah tervalidasi DAN sesuai cakupan sektor.
5. Integrasi Fitur	Penggabungan cuaca + fitur spasial-temporal + topografi + antropogenik menjadi satu matriks fitur.
6. Pattern Discovery	Clustering & ekstraksi rule archetype dari matriks fitur final.

4.2 Definisi "Eskalasi Tervalidasi" — Perbaikan Metodologis Penting

Draf awal riset ini mendefinisikan eskalasi secara heuristik: cluster kecil yang jumlah titik panasnya melonjak $\geq 3x$ dalam 3 hari. Definisi ini rentan dikritik — "kenapa harus 3x, kenapa bukan 2x atau 5x?" — karena bersifat self-referential (FIRMS dipakai untuk memprediksi FIRMS sendiri).

Definisi final memperbaiki ini dengan menambahkan ground truth independen:

- Secara heuristik, FIRMS menunjukkan lonjakan pada persentil ke-95 dari distribusi rasio pertumbuhan (bukan angka bulat sembarang seperti 3x);
- Lonjakan tersebut dikonfirmasi silang oleh MODIS Burned Area (MCD64A1) — apakah sel grid itu benar-benar tercatat sebagai area terbakar (memakai atribut burn date per piksel, bukan info bulanan agregat) pada rentang tanggal yang relevan.

Label positif hanya diberikan jika kedua kondisi terpenuhi. Kandidat heuristik yang tidak terkonfirmasi MCD64A1 justru didokumentasikan sebagai temuan tersendiri untuk menjawab RQ2 — mengapa FIRMS menunjukkan sinyal eskalasi tapi tidak berkembang menjadi area terbakar riil.

4.3 Klarifikasi Metodologis: Tiga Miskonsepsi yang Perlu Diluruskan

Metodologi ground truth di atas sering memicu tiga pertanyaan lanjutan — baik dari reviewer, dosen, maupun tim sendiri saat pertama kali menyusun pipeline. Ketiganya dijawab eksplisit di sini agar tidak menimbulkan miskonsepsi saat presentasi.

Miskonsepsi #1 — "Apakah perlu menghitung dNBR sendiri dari citra Sentinel-2 mentah?"

Tidak perlu. dNBR (Delta Normalized Burn Ratio) adalah metodologi standar remote sensing untuk deteksi burned area, dan MCD64A1 sudah menerapkan pemrosesan spektral setara di dalam pipeline produksinya oleh NASA — atribut BurnDate per piksel adalah hasil akhir dari proses tersebut, bukan bahan mentah yang perlu diproses ulang. Menghitung dNBR sendiri dari citra Sentinel-2 pre-fire/post-fire (mencari pasangan citra bebas awan, menghitung NBR dua kali, menentukan threshold manual) akan menjadi pekerjaan duplikat yang berat untuk hasil yang secara prinsip sudah setara dengan yang tersedia di MCD64A1.

Miskonsepsi #2 — "Bagaimana definisi Label 0 (tidak eskalasi) yang benar?"

Metodologi umum image classification (random sampling piksel di luar polygon burned area sebagai label negatif) tidak berlaku di sini, karena task risetnya berbeda secara mendasar. Riset ini bukan soal "piksel mana saja yang terbakar" (land-cover classification), melainkan "dari cluster hotspot yang SUDAH terdeteksi FIRMS, mana yang membesar signifikan" (dinamika pertumbuhan cluster). Maka:

- Label 1: cluster hotspot FIRMS yang memenuhi heuristik persentil-95 DAN dikonfirmasi MCD64A1 BurnDate pada window waktu yang sama.
- Label 0: cluster hotspot FIRMS (bukan piksel acak di luar polygon burned area) yang tidak memenuhi salah satu atau kedua syarat di atas — tetap titik api asli yang terdeteksi satelit, bukan piksel kosong tanpa aktivitas.

Miskonsepsi #3 — "Apa peran visualisasi false-color (Sentinel-2 band 12, 8, 4)?"

Bukan untuk pelabelan massal — tidak scalable untuk memproses ribuan cluster satu per satu secara visual. Perannya adalah bukti kualitatif pendukung: 2–3 contoh cluster berlabel eskalasi ditunjukkan overlay-nya pada komposit false-color di Bab Analisis atau Pattern Library, sebagai validasi visual bahwa label tervalidasi memang match dengan kejadian nyata di citra satelit — bukan sekadar angka statistik dalam tabel.

Ringkasan posisi ketiga elemen dalam pipeline

dNBR — sudah terwakili di dalam produk MCD64A1, tidak dihitung ulang secara manual.

Label 0 — cluster hotspot FIRMS yang tidak lolos validasi, bukan sampel acak di luar area terbakar.

False-color Sentinel-2 — alat bukti visual kualitatif untuk laporan, bukan mekanisme pelabelan utama.

5. Metodologi & Model Machine Learning

Metodologi disusun sebagai alur sembilan langkah, dari feature engineering hingga penyusunan Pattern Library sebagai kontribusi akhir. Setiap langkah memakai teknik yang dipilih secara spesifik sesuai perannya — bukan sekadar "model yang paling populer".

Langkah	Teknik / Model	Peran dalam Riset
1. Grid & Agregasi	Grid spasial 0.1° (~11km)	Agregasi harian jumlah titik panas & total FRP per sel sebagai unit analisis.
2. Filtering Sanitasi	Spatial overlay (GeoPandas)	Menandai is_peatland dan membuang sel dominan urban/industri.
3. Label Eskalasi	Persentil ke-95 + validasi MCD64A1	Menghasilkan label ground truth yang defensible (lihat Bagian 4.2–4.3).
4. Feature Engineering Interaksi	Fitur interaksi eksplisit (mis. precip_dry_streak × is_peatland)	Membentuk sinyal gabungan yang merepresentasikan tiap dugaan archetype sejak awal.
5. Modeling Prediktif	LightGBM + scale_pos_weight (cost-sensitive)	Model dasar yang menangani ketidakseimbangan kelas (kejadian eskalasi jauh lebih jarang dari non-eskalasi); bukan tujuan akhir, tapi fondasi untuk SHAP di langkah berikutnya.
6. Explainability Mendalam	SHAP Interaction Values (bukan feature importance biasa)	Mengidentifikasi PASANGAN fitur yang berinteraksi kuat memicu eskalasi — input untuk clustering archetype.
7. Archetype Discovery	K-Means / Hierarchical Clustering pada ruang fitur interaksi	Menemukan kluster alami pola eskalasi — dicek apakah cocok dengan 4 dugaan awal atau muncul archetype baru yang tak terduga.

Langkah	Teknik / Model	Peran dalam Riset
8. Knowledge Extraction	Association Rule Mining — Apriori (mlxtend)	Menghasilkan rule IF-THEN bertipe support/confidence/lift, dikelompokkan per archetype hasil langkah 7.
9. Pattern Library	Kurasi manual + agregasi statistik	Katalog akhir: nama archetype, rule defining, kondisi lingkungan tipikal, rekomendasi intervensi, dan contoh kasus historis.

5.1 SHAP Interaction Values vs. Association Rule Mining — Dua Hal yang Berbeda

Dua teknik ini sering disalahpahami sebagai hal yang sama, padahal perannya berurutan dan berbeda fungsi: SHAP adalah alat explainability — menjelaskan kontribusi tiap fitur terhadap SATU prediksi. Association Rule Mining adalah alat knowledge extraction — menemukan pola IF-THEN yang berlaku umum dari KESELURUHAN data. SHAP dipakai lebih dulu untuk menemukan pasangan fitur yang penting, baru rule mining dipakai untuk merumuskan pola itu menjadi aturan yang bisa dibaca manusia.

Contoh Output Rule (ilustrasi format akhir)

Rule (Peat-driven): Peatland=True $\wedge$ Precip=0 (14 hari) $\wedge$ Δ FRP $\uparrow$ $\Rightarrow$ Smoldering Escalation (support=6%, confidence=84%, lift=3.2)

Rule (Wind-driven): Windspeed>X $\wedge$ Humidity<Y% $\wedge$ NeighborDensity $\uparrow$ $\Rightarrow$ Fast Surface Escalation (support=4%, confidence=87%, lift=4.1)

5.2 Arsitektur Sistem: Training vs. Operasional (Near Real-Time)

Fase	Sumber Data	Output
Fase 1 — Offline Training & Taxonomy Discovery	FIRMS + Open-Meteo + Land Cover + Gambut + Burned Area + NDVI + Topografi (2020–2026)	Archetype dan rule terbentuk dari data historis.
Fase 2 — Triase Operasional (simulasi NRT)	FIRMS NRT (delay ~3 jam) + Open-Meteo Forecast API	Klasifikasi cluster baru ke archetype + skor risiko $\rightarrow$ peta triase dengan rekomendasi strategi per archetype.

Istilah yang dipakai secara konsisten adalah "near real-time", bukan real-time murni — ini bukan kelemahan sistem, melainkan keterbatasan inheren dari satelit orbit polar yang melintasi satu wilayah beberapa kali sehari, bukan terus-menerus.

6. Nilai Kebaruan & Daya Saing Riset

Bagian ini menjawab pertanyaan yang paling mungkin diajukan dosen atau juri: apa yang membuat riset ini berbeda dan sulit ditiru tim lain?

Elemen Pembeda	Penjelasan
Label ground truth independen	Sebagian besar riset sejenis memakai heuristik FIRMS untuk memprediksi FIRMS sendiri (self-referential). Riset ini memvalidasi silang dengan MODIS Burned Area (MCD64A1) — produk satelit NASA yang independen — sehingga label jauh lebih defensible di depan reviewer.
Pergeseran dari prediksi ke taxonomy discovery	Kontribusi utama bukan skor probabilitas biner, melainkan taksonomi archetype dan Pattern Library terstruktur — model prediksi (LightGBM) hanya alat bantu, bukan tujuan akhir.
Kombinasi teknik berlapis yang jarang dipakai bersamaan	SHAP Interaction Values → Clustering → Association Rule Mining adalah rangkaian eksplainabilitas bertingkat yang jarang diimplementasikan secara utuh dalam satu pipeline karhutla di konteks Indonesia.
Hipotesis kuantitatif yang falsifiable	H1 (Paradoks Pareto) memberi klaim terukur dan bisa diuji/disalahkan, bukan sekadar narasi kualitatif — memperkuat kredibilitas ilmiah laporan.
Kejujuran metodologis by design	Jika archetype hasil clustering tidak cocok dengan 4 dugaan awal, itu didokumentasikan apa adanya sebagai temuan — bukan dipaksakan. Ini justru memperkuat validitas riset sebagai discovery yang genuin, bukan konfirmasi asumsi.
Relevansi operasional langsung	Output akhir berupa rekomendasi intervensi spesifik per archetype (sekat bakar cepat untuk wind-driven vs pembasahan lahan untuk peat-driven) — langsung actionable untuk BPBD/Mangala Agni, bukan sekadar metrik akademik.

6.1 Kesejajaran dengan Society 5.0 & SDGs

- Human-centered: keselamatan warga di wilayah rawan asap/api melalui strategi intervensi yang presisi per archetype.
- Cyber-Physical System integration: satelit (fisik) → archetype classifier (siber) → strategi patroli spesifik (aksi fisik).
- Masalah terukur: hasil uji H1 (persentase cluster vs kontribusi FRP) dan jumlah rule tervalidasi per archetype.
- SDGs: SDG 13 (Climate Action) dan SDG 15 (Life on Land).

7. Timeline Pengerjaan

Tanggal	Fokus	Output
4 Agu	Setup GEE, uji H1 dengan data FIRMS riil, mulai tarik MCD64A1	H1 teruji + akses GEE siap

Tanggal	Fokus	Output
5 Agu	Selesaikan MCD64A1 + peta gambut + SRTM, bentuk label eskalasi final	Label tervalidasi ground truth
6 Agu	Land cover + NDVI, feature engineering interaksi	Dataset fitur lengkap
7 Agu	Modeling cost-sensitive + SHAP Interaction Values	Model + pasangan fitur interaksi kunci
8 Agu	Archetype clustering	Taksonomi archetype teridentifikasi
9 Agu	Association Rule Mining	Daftar rules per archetype
10 Agu	Pattern Library curation + OSM/WorldPop jika sempat	Katalog Pattern Library lengkap
11–12 Agu	Penulisan Technical Report 8 bagian penuh	Naskah 100%
13 Agu	Simulasi demo NRT, uji similaritas, surat pernyataan, polish	Siap review
14 Agu	Review akhir, submit	Selesai

8. Risiko & Mitigasi

Risiko	Mitigasi
Setup/autentikasi GEE molor di hari pertama	Alokasikan blok waktu khusus di pagi hari 1, tidak digabung task lain.
Resolusi bulanan MCD64A1 tidak match window 3 hari	Pakai atribut burn date per piksel (bukan info bulanan agregat) untuk presisi harian.
Archetype clustering tidak menghasilkan kluster yang jelas/interpretable	Coba beberapa jumlah kluster (elbow method); siapkan narasi jujur jika hasilnya 2–3 archetype dominan, bukan 4 — tetap valid sebagai temuan.
Waktu habis sebelum Tier 3 (OSM/WorldPop) selesai	Sudah diantisipasi lewat tiering — laporan tetap solid tanpa itu.
H1 tidak terbukti timpang	Tidak dipaksakan; RQ2 (kenapa cluster serupa berbeda nasib) tetap valid sebagai motivasi archetype tanpa perlu H1 ekstrem.

9. Kesimpulan

Riset ini menempatkan kontribusi utamanya bukan pada akurasi model prediksi, melainkan pada Pattern Library — katalog terstruktur archetype eskalasi karhutla yang tervalidasi ground truth dan langsung dapat diterjemahkan menjadi strategi intervensi operasional. Keterbatasan disampaikan secara jujur:

jumlah archetype yang ditemukan merupakan hasil clustering pada data historis dan tetap memerlukan validasi lapangan berkelanjutan.

Dokumen ini diharapkan memberi dosen pembimbing gambaran lengkap — dari urgensi masalah, keputusan teknis pemrosesan data, klarifikasi metodologis ground truth, hingga rangkaian model yang dipakai — sebagai satu kesatuan argumen yang koheren dan siap didiskusikan.